AI智能体记忆架构：当前局限、技术瓶颈与未来突破方向深度研究报告

引言与行业演进背景

随着大型语言模型（LLM）从静态的文本响应生成器演变为具备自主规划、工具调用和长期交互能力的智能体（Agent），记忆架构已成为决定其认知上限的核心基础设施。传统的自回归模型在本质上是无状态的，其所有的“记忆”仅存在于当前调用的上下文窗口之中。当会话结束或上下文窗口溢出时，模型会经历灾难性的系统遗忘。早期的检索增强生成（RAG）技术试图通过外部向量数据库来缓解这一问题，但纯粹的语义相似度检索无法捕获时间序列、因果关系以及智能体自身的状态演变。

近年来，智能体的开发范式正经历从“提示词工程”向“上下文工程”的深刻转变[1]。行业研究表明，智能体的性能瓶颈已不再仅仅是基础模型的推理能力，而是如何在高频交互中维持、过滤并更新长期的上下文状态。为了解决这一痛点，包括Anthropic提出的模型上下文协议（Model Context Protocol, MCP）在内的多项标准化努力，正试图统一智能体与外部数据存储交互的边界[2]。然而，随着智能体在企业级数据环境和长时间跨度的交互中部署，当前的记忆架构暴露出深层的技术局限性。从上下文污染、键值缓存（KV Cache）的经济学约束，到缺乏系统性垃圾回收机制以及合规层面的机器遗忘难题，现有的外挂式记忆库已难以支撑下一代系统的需求。本报告将系统性剖析智能体记忆框架的分类、核心技术瓶颈，并深入探讨测试时训练（TTT）、睡眠启发记忆巩固及信息几何等未来突破方向。

记忆系统的认知分类学与理论基础

当代智能体记忆架构深受认知科学的启发，特别是Endel Tulving于1972年对人类记忆系统的分类，以及Larry Squire在1987年对程序性记忆的补充[4]。将这些人类认知理论映射到计算系统中，形成了智能体记忆的基础分类学，每一种记忆类型在系统中都承担着不同的信息留存与推理功能。

记忆类型	认知科学起源	核心功能与存储内容	技术实现路径与特征
工作记忆 **(Working Memory)**	Baddeley (1974)	瞬时目标、临时计算结果、挂起操作及当前对话的滑动窗口。	LLM上下文窗口内的提示词、近期对话缓冲区。受限于Token容量。
情景记忆 **(Episodic Memory)**	Tulving (1972)	带有严格时间、空间和因果关系戳的过去具体事件记录。	结构化JSON日志、交互流、带时间戳的代理决策周期。通常通过向量或图检索。
语义记忆 **(Semantic**	Tulving (1972)	脱离具体事件背景的抽象事实、世界	知识图谱、经由反思机制（Reflection）

Memory)		模型、用户偏好及领域知识。	从情景记忆中提炼的事实库、预训练权重。
程序记忆 **(Procedural Memory)**	Squire (1987)	指导智能体如何行动的内隐规则、工作流逻辑、工具调用路由。	技能库（如Voyager的程序库）、系统指令、通过SFT或RL更新的模型权重。
组织/身份记忆 **(Organizational Memory)**	现代多智能体架构	持久的身份特征、企业级数据治理策略、访问控制及溯源机制。	集中管理的合规策略引擎、带版本控制与审批时间戳的上下文层。

在这些记忆类型中，情景记忆的写入要求极高的保真度。Tulving的绑定原则（Binding Principle）强调，事件及其上下文（时间、空间、因果）必须以足够的分辨率完整保存，以便将该事件与所有类似事件区分开来[4]。如果代理系统在写入时即执行摘要压缩，将导致不同事件在语义上被过度泛化，从而破坏情景信号的可用性[4]。与此同时，语义记忆在现代企业环境中往往缺乏治理状态。未经认证和缺乏版本控制的语义定义容易导致智能体输出未经审计的错误答案，这就要求引入更高维度的组织记忆架构来进行企业级的上下文治理[5]。

当前主流智能体记忆架构范式深度剖析

自2023年生成式智能体（Generative Agents）引入基于近期性（Recency）、重要性（Importance）和相关性（Relevance）的混合记忆检索公式以来[6]，记忆架构经历了快速演进。当前市场存在几种截然不同的流派，它们在读写机制、控制权归属以及系统层级上存在根本性差异。

自主管理与操作系统隐喻：Letta (MemGPT) 与 MemOS

以Letta（原MemGPT）和MemOS为代表的架构，深刻贯彻了将大型语言模型视为中央处理器（CPU）的隐喻。Letta放弃了由外部流水线被动检索数据的思路，转而将上下文窗口视为随机存取存储器（RAM），外部存储视为磁盘，赋予智能体自主调用工具来分页、读写和重写自身记忆的能力[10]。Letta的架构将记忆划分为四个逐级有损压缩的层级：驻留在提示词中的核心记忆（包含角色设定与不变规则）、滚动截断的消息缓冲区、外部向量支持的归档记忆，以及按需提取的召回记忆[1]。这种设计的核心在于将“压缩”作为一种认知思考过程，允许模型通过自我反思自主决定保留何种事实。然而，其代价是记忆行为在不同模型间的不可预测性，且高度依赖模型自身的工具调用能力[13]。

近期的MemOS系统进一步抽象了这一概念，提出了“MemCube”作为标准化的内存封装单元，统一管理明文记忆、激活态记忆（KV Cache）和参数记忆[15]。MemOS引入了类似传统操作系统的调度器（MemScheduler）与生命周期管理器，支持跨类型记忆的融合与演化。在评估中，MemOS通过引入“下一场景预测”机制在推理时主动预加载相关片段，在时序推理任务上相比基线方案实现了显著的性能提升，并将Token开销降低了近60%[17]。

被动提取流水线与记忆即服务：Mem0 与 Feather DB

与Letta赋予智能体自主控制权不同，Mem0采用了一条更具确定性和可预测性的被动提取路径。Mem0作为一个纯粹的记忆层，在每次对话输入时，通过后台的独立语言模型流水线主动提取结构化事实（如用户偏好），并将其存入云端索引[13]。这种架构将记忆操作移出了主智能体的推理预算，保证了同一输入产生相同记忆的一致性。

在追求极致延迟与成本控制的场景下，Feather DB提供了一种嵌入式C++库方案。它不仅支持倒排索引（BM25）与密集向量的互惠等级融合（RRF），还引入了自适应衰减机制（结合粘性、半衰期与重要性）[19]。测试显示，Feather DB的检索延迟（p50）仅为0.19毫秒，远低于API调用的50-200毫秒，展现出极高的本地化部署优势[19]。

时序知识图谱与双时态架构：Zep、Graphiti 与 Sentra

传统纯向量检索在处理状态变化时存在致命缺陷，极易引发模型幻觉。例如，面对随着时间发生改变的用户偏好或业务状态，传统知识图谱或向量库往往将新旧事实并列召回。为解决此问题，Zep及其开源框架Graphiti引入了时序知识图谱（Temporal Knowledge Graph）[20]。在双时态图谱中，任何图谱边缘不仅携带语义信息，还强制包含其“有效时间窗口”。当新事实输入时，旧事实不会被物理删除，而是被标记为失效（Invalidated），从而保留了完整的历史渊源（Provenance）[20]。

进一步扩展到多智能体协作场景，Sentra系统提供了一个企业级共享的双时态图谱。与Letta将记忆限定在单个智能体生命周期内不同，Sentra致力于构建公司范围内的单一治理事实来源[23]。在此模式下，任何智能体习得的事实都会被全局验证与共享，从根本上防止了跨智能体协作中的上下文割裂现象。

模块化与可移植性追踪：Portable Agent Memory

针对各大平台间存在的供应商锁定（Vendor Lock-in）和会话失忆（Session Amnesia）问题，Portable Agent Memory提出了一种基于默克尔有向无环图（Merkle-DAG）的五组件存储结构（情景、语义、程序、工作、身份）[10]。其默克尔图结构实现了三大关键目的：第一是推导追踪，确保每一条从情景观察中提取的语义事实都带有可审计的来源链；第二是防篡改验证，任何下游的记忆修改都会使哈希链失效，保证了代理行为基础的可靠性；第三是选择性披露，允许用户在不同平台间安全导出记忆子集[10]。

记忆系统面临的当前局限与核心技术瓶颈

当智能体在企业数据环境中执行复杂任务时，上述工程框架暴露出深层的数学与计算瓶颈，主要集中在上下文污染、KV Cache经济学、垃圾收集失效及机器遗忘四个维度。

上下文污染与“中间迷失”困境

智能体的工作记忆严格受制于上下文窗口的有效容量。在生产系统中，单次智能体调用携带五个主要上下文片段：系统提示（2K-6K Token）、工具模式描述（随MCP工具扩散呈爆炸式增长）、对话历史、工具输出（往往包含庞大且未解析的JSON负载）以及检索召回的上下文[2]。其中，检索内容和未解析的工具输出是最大的容量消耗者。

研究表明，当大量未经过滤的块被注入窗口时，会产生严重的“上下文污染”（Context Pollution）[2]。在NoLiMa基准测试中，明确记录了模型准确率在上下文长度达到32K时会出现高达50%的“32K悬崖”式下跌（32K Cliff现象），证明单纯增大窗口容量不仅无法消除“中间迷失”（Lost in the Middle）效应，反而会改变模型的内部注意力权重分配，导致其偏离既定工作流[2]。为应对此问题，MemInsight等框架通过在协作多代理机制中引入显式的上下文隔离来缓解污染[27]，而研究更指出，严格的写入时过滤（Write-time filtering）可以使得代理的任务准确率直接提升10%[28]。

KV Cache 经济学与架构悖论

在复杂任务的代理推理循环中，交互模式呈现出极端的读写不平衡现象。例如Manus代理系统的遥测数据表明，代理流量是重预填充（Prefill）和轻解码（Decode）的，输入Token与输出Token的平均比例高达100:1[2]。由于Transformer的无状态特性，每次调用都必须重传完整的轨迹。这就使得推理成本和延迟压倒性地由键值缓存（KV Cache）的命中率所决定。

KV Cache重用大幅降低了长上下文的处理成本。然而，当前的动态记忆管理策略往往与KV Cache机制直接冲突。无论是动态修改系统提示中的时间戳、变更可用工具列表，还是使用滚动摘要替换旧对话，都会破坏共享前缀，导致缓存失效[2]。为从底层解决此问题，DeepSeek在V4.1-Flash中通过多头潜在注意力（MLA）等技术，将全局KV字节压缩至每Token 890 B（比V1降低438倍），并引入了196B参数的Engram条件记忆模块，使得缓存命中的成本降至每百万Token 0.006美元[2]。这种从架构层面优化的路径表明，记忆瓶颈最终必须在缓存经济学的框架内解决。

记忆垃圾回收（GC）危机与艾宾浩斯衰减机制

如果一个智能体事无巨细地存储所有信息，它最终将因记忆库中充斥着陈旧、矛盾或低质量的条目而崩溃。实验数据证明，采用“全盘记录”策略的智能体在医学推理任务中累积至2400条记录时，准确率骤降至13%；而采用主动记忆管理的系统在保持248条核心记录的情况下，准确率维持在39%[28]。这表明记忆系统真正面临的是垃圾回收（GC）问题。

人类认知通过选择性遗忘来优化检索信号的信噪比。艾宾浩斯遗忘曲线（Ebbinghaus Forgetting Curve）揭示了记忆保留率随时间的指数衰减机制：$R = \exp(-t/S)$，其中R为保留率，t为时间，S为记忆强度[29]。在计算系统中引入这种带有半衰期的遗忘算法（如30天半衰期衰减因子），使得旧有且不相关的记录在检索优先级中自然下沉[31]。然而，不同类型的记忆应当具备不同的衰减速率，例如用户的核心个性特征应具有极长的保留期，而短期情绪和陈述性意图则应在数天内消退，否则单一衰减率将使其退化为普通的LRU缓存[32]。

更进一步，最近的强化学习研究提出了“遗忘系统”（Forgetting Systems）的概念框架。针对智能体部署后习得的有害或冗余行为-状态关联，该系统引入了渐进式权重衰减（Gradual Weight Decay）机制，其动态遗忘强度公式 $\lambda = \alpha_1\tau_1 + \alpha_2\tau_2 + \alpha_3\epsilon$ 通过触发条件评估，使得特定有害行为的权重 $w^k \to 0$。这种通过衰减而非物理删除的方式，将遗忘视为一种控制机制而非记忆失败[33]。

数据合规与机器遗忘的工程挑战

在欧盟《通用数据保护条例》（GDPR）和《人工智能法案》确立的“被遗忘权”（Right to be Forgotten）背景下，记忆系统的合规审查日益严格[34]。如果智能体的记忆以明文或向量的形式存在于外部数据库（如RAG架构），删除敏感的个人身份信息（PII）仅需执行数据库的检索与抹除操作[34]。

然而，如果记忆信息通过微调或反思机制被固化进入模型自身的参数空间，实现真正意义上的删除就演变为极具挑战性的“机器遗忘”（Machine Unlearning）问题[34]。由于神经网络参数的纠缠特性，单纯过滤提示词无法彻底抹除内部概念表征。缺乏SISA（分片、隔离、切片、聚合）等高级解耦技术的系统，可能会因一条违规数据而面临被迫销毁并重新训练整个千亿级模型的风险[34]。这使得在架构设计上，将可变事实与不可变参数进行严格的物理隔离成为现阶段企业级部署的标准准则。

前沿突破方向与下一代记忆机制

为突破上下文极限与外部检索的瓶颈，学术界正在进行深刻的范式转移，研究焦点从外部存储转向融合参数化更新、生物学启发的记忆巩固，以及底层拓扑结构。

测试时训练（TTT）与快速权重记忆

测试时训练（Test-Time Training, TTT）与快速权重（Fast Weights）被视为下一代长程记忆架构的核心解法。传统的上下文学习（ICL）在序列结束时丢弃所有激活状态，而TTT方法允许模型在推理阶段，通过自监督目标（如重构损失或未来Token预测）实时更新一小部分内部参数（如线性状态或LoRA权重）[40]。在快速权重rollout动态中，策略动作由基础慢权重与在线快权重的组合 $W_0 + A_t$ 决定。代理提取出的经验自动转化为监督信号以更新 A_t，使其在单次生命周期内即可真正“内化”经验[40]。

为了克服传统TTT逐Token更新带来的序列化计算瓶颈，E2-TTT（Expressive and Efficient TTT）等算法引入了块级别（Chunk-wise）的闭式更新。该机制通过输入依赖的门控动态方程，在保留滑动窗口注意力（SWA）以处理局部因果交互的同时，通过快速权重状态实现了跨块的信息传递[41]。这种架构从根本上突破了注意力计算复杂度的软硬天花板，在参数空间内实现了记忆与推理的一体化[42]。

睡眠启发的记忆巩固与递归更新机制

生物学中，记忆的系统性巩固发生于睡眠期间。海马体中的短期情景记忆通过尖锐波涟漪（Sharp-wave ripples）的离线重放，被转移至新皮层形成长期语义记忆，同时通过突触降尺度（Synaptic downscaling）削弱无关痕迹[35]。近期研究成功将此双相机制引入大语言模型智能体，提出了以SleepGate为代表的记忆巩固框架[45]。

在休眠阶段，智能体不再受限于实时交互的延迟要求，而是利用内置模块执行多次离线的递归前向传递[46]。系统提取近期积累的情景轨迹，利用遗忘门（Forgetting Gate）进行选择性保留，将有价值的因果关系蒸馏并写入到快速权重记忆块（如状态空间模型 SSM模块）中，随后清空庞大且冗余的KV缓存。在重新唤醒后，模型凭借更新后的内部权重即可对历史进行深层推理，极大提升了模型在涉及复杂数学推理与长期时间序列问题上的处理能力[46]。

颅脑启发门控（CraniMem）与结构化蒸馏

为了从源头上阻断上下文污染，新型记忆设计致力于在信息进入推理窗口前进行极度压缩与门控。CraniMem架构受到神经认知的启发，采用目标条件门控（Goal-conditioned gating）和基于效用的修剪策略。该系统结合了用于近期连续性的有界情景缓冲区与用于持久语义召回的结构化知识图谱，通过严格的效用打分，仅允许对当前推断最直接相关的语义线索进入工作记忆。评估表明，这种效用修剪比传统的全量RAG显著提高了在嘈杂环境下的任务成功率[47]。

相辅相成的是结构化蒸馏（Structured Distillation）技术。针对包含大量无效试错的冗长代理轨迹，结构化蒸馏算法通过迭代抽象对话逻辑，能够在完美保留检索精度的前提下，实现高达11倍的Token缩减[51]。这类技术的突破，使得智能体在极低计算负荷下，依然能够随身携带超长周期的个性化交互历史。

信息几何与拓扑一致性图谱

在极大规模的多智能体协作环境中，数百个并发代理对共享记忆体的读写往往引发深度的拓扑逻辑不一致，而不仅仅是表面上的时间戳冲突。SuperLocalMemory（SLM）框架创新性地引入了信息几何（Information Geometry）与层状上同调（Sheaf Cohomology）的纯数学工具来应对这一挑战[35]。

在SLM的理论框架下，存储库被建模为一个图上的细胞层（Cellular sheaf）。每个上下文节点对应

一个局部记忆声明的向量空间，而相连边缘代表必须遵守的限制映射与语义兼容性。任何局部到全局无法调和的记忆冲突，都会在代数结构中精确对应于一个非平凡的上同调类。借助庞加莱双曲几何空间（Poincaré ball）和朗之万动力学，该框架实现了包括语义、BM25、时序、霍普菲尔德网络以及图遍历在内的六通道融合检索，能在数学证明的层面上保证多智能体信息交互的收敛与一致性。SLM系统完全运行于本地CPU，有效规避了欧盟《人工智能法案》（EU AI Act）关于数据主权与隐私外泄的限制风险[35]。

综合基准测试与系统评估分析

随着系统的演化，学术界与工业界构建了多维度的基准测试来衡量记忆性能，包括评估长程事实召回的LongMemEval、侧重多轮时序逻辑的LoCoMo、以及专门针对复杂应用环境的AppWorld。

评估基准 / 指标	典型系统表现	关键数据与性能特征
LongMemEval	Mem0 / Zep / SLM	Mem0达到94.4%准确率[55]；Zep表现优异（~94.8%）且检索延迟低至104ms[56]；SLM结合Gemini通过混合通道达到0.657准确度但成本极低[19]。
LoCoMo	Mem0 / Letta / MemOS	Mem0最新算法达92.5%[55]；Letta依靠文件存储架构达到约74.0%[55]；MemOS在此基准上表现卓越，相对OpenAI全局记忆方案获得159%的提升[17]。
EpBench	向量库基线 / GSW	测试模型对时间顺序的排列。传统模型正确排序多事件的概率极低（<36%），而GSW架构通过结构化语义表示使F1得分提升至0.850[4]。
DMR (Dynamic Memory Retrieval)	Zep / MemGPT	侧重动态深层事实更新。Zep（94.8%）略高于MemGPT基线（93.4%），在时效事实覆盖问题上表现更好[2]。
AppWorld	TTT / CraniMem	在持留任务中引入测试时记忆管理，实现高达14.3%的目标完成度增益及149%的复杂任务相对提升[50]。

上述数据明确反映出，从单纯的检索（Retrieval）演变为有治理、有压缩机制的主动记忆管理，是提

升时序推理和消除矛盾的必由之路。

结语

AI智能体记忆架构正处于从外部辅助工具向核心计算范式转变的历史拐点。现有的基于文本块存储与向量相似度检索的拼接系统，在应对上下文污染、KV缓存经济学限制以及复杂事实的拓扑冲突时，已显露疲态。未来的智能体记忆绝非仅是存储容量的横向扩展，而是模型架构深度的垂直演进。

无论是将记忆编码于微调权重的测试时训练（TTT）机制，模拟生物学遗忘与巩固的离线睡眠调度（SleepGate），还是基于信息几何重构知识拓扑一致性（SLM），其演进目标高度一致：使智能体摆脱无状态的上下文束缚，赋予其连续、连贯且可自我净化的认知生命周期。那些能够将工作记忆的敏捷性、情景记忆的精确溯源与参数记忆的深厚底蕴进行无缝操作系统级融合（如MemOS的构想）的架构，必将成为通向下一代通用人工智能（AGI）不可或缺的核心基础设施。

Works cited

1. Agent Memory: How to Build Agents That Learn and Remember - Letta, https://www.letta.com/blog/agent-memory/
2. Context Management in Agent Loops - Local AI Zone, https://local-ai-zone.github.io/blog/context-management-agent-loops-research-paper.html
3. Breaking Down Model Context Protocol (MCP) - Botpress, https://botpress.com/blog/model-context-protocol
4. Episodic Memory for AI Agents: How It Works and Why It Matters, https://atlan.com/know/episodic-memory-ai-agents/
5. Types of AI Agent Memory: Episodic, Semantic, Procedural and More, https://atlan.com/know/types-of-ai-agent-memory/
6. 10: Memory & Retrieval for LLMs - Oscar Health, https://www.hioscar.ai/10-memory-and-retrieval-for-llms
7. Generative Agents: Interactive Simulacra of Human Behavior, https://abhinavchinta.com/files/generative_agents_talk.pdf
8. Generative Agents: Interactive Simulacra of Human Behavior, https://fanpu.io/summaries/2023-08-11-generative-agents-interactive-simulacra-of-human-behavior/
9. Generative Agents: Interactive Simulcra of Human Behavior - Medium, https://marekpaulik.medium.com/generative-agents-interactive-simulcra-of-human-behavior-648c32a76b9
10. Portable Agent Memory: A Protocol for Provenance-Verified ... - arXiv, https://arxiv.org/html/2605.11032v1
11. Layers of Memory, Layers of Compression - Tim Kellogg, https://timkellogg.me/blog/2025/06/15/compression
12. Letta - LLMS3.com, https://llms3.com/node/letta/
13. Mem0 vs Letta: Which AI Memory Solution Should You Choose?, https://gamgee.ai/vs/mem0-vs-letta/
14. Mem0 vs Letta (MemGPT): AI Agent Memory Compared (2026), https://vectorize.io/articles/mem0-vs-letta

15. MemOS: A Memory OS for AI System, https://memorypapers.org/papers/memos-memory-os-ai
16. (PDF) MemOS: An Operating System for Memory-Augmented, https://www.researchgate.net/publication/392167750_MemOS_An_Operating_System_for_Memory-Augmented_Generation_MAG_in_Large_Language_Models
17. Paper page - MemOS: A Memory OS for AI System - Hugging Face, https://huggingface.co/papers/2507.03724
18. MemOS: A Memory OS for AI Systems - Medium, https://cbarkinozer.medium.com/memos-a-memory-os-for-ai-systems-d1f5242cca14
19. AI Memory Systems in 2026: Feather DB, Mem0, Zep, Letta Compared, https://www.getfeather.store/theory/ai-memory-systems-comparison-2026
20. getzep/graphiti: Build Real-Time Knowledge Graphs for AI Agents, https://github.com/getzep/graphiti
21. What Is a Temporal Knowledge Graph? Definition - Zep, https://www.getzep.com/ai-agents/temporal-knowledge-graph/
22. Zep: A Temporal Knowledge Graph Architecture for Agent Memory, https://arxiv.org/html/2501.13956v1
23. Sentra vs Letta (2026): Which Scales to a Team, https://www.sentra.app/articles/sentra-vs-letta
24. MemGPT: Engineering Semantic Memory through Adaptive, https://informationmatters.org/2025/10/memgpt-engineering-semantic-memory-through-adaptive-retention-and-context-summarization/
25. Long-Term vs Short-Term AI Memory: Key Design Differences - Atlan, https://atlan.com/know/long-term-vs-short-term-ai-memory/
26. arXiv:2601.10657v3 [cs.NE] 10 Sep 2026, https://arxiv.org/pdf/2601.10657
27. Multi-Paradigm Agent Interaction in Practice - arXiv, https://arxiv.org/pdf/2605.16821
28. Agent Memory Garbage Collection: Engineering Strategic Forgetting, https://tianpan.co/blog/2026/04/14/agent-memory-garbage-collection
29. Ebbinghaus's Forgetting Curve: How to Overcome It - Whatfix, https://whatfix.com/blog/ebbinghaus-forgetting-curve/
30. ai, memorization, and forgetting: a critical analysis through the lens, https://www.researchgate.net/publication/391847984_AI_MEMORIZATION_AND_FORGETTING_A_CRITICAL_ANALYSIS_THROUGH_THE_LENS_OF_THE_EBBINGHAUS_CURVE
31. TIL: Memory decay actually makes retrieval BETTER, not worse, https://www.moltbook.com/post/783de11a-2937-4ab2-a23e-4227360b126f
32. Show HN: AI memory with biological decay (52% recall), https://news.ycombinator.com/item?id=47914367
33. A Theoretical Framework for Selective Behavioral Erasure in Post, https://www.preprints.org/manuscript/202606.0911
34. [AI Burst] You Can't Delete What You Can't Find - Hype Check Live, https://news.hypechecklive.com/p/you-cant-delete
35. SuperLocalMemory V3: Information-Geometric Foundations for Zero,

https://arxiv.org/pdf/2603.14588
36. RAG vs Fine-Tuning: 2026 AI Model Optimization Strategies, https://zignuts.com/blog/rag-vs-fine-tuning
37. UNRE: ZERO-SHOT LLM UNLEARNING VIA DY - OpenReview, https://openreview.net/pdf?id=3ZesmvOJ6o
38. Managing the Unmanageable: Multimodal Artificial Intelligence for, https://www.mdpi.com/2673-6470/6/3/68
39. OWASP GenAI Data Security - MateMatic, https://matematicsolutions.com/baza-wiedzy/pdf/2026-05-12-owasp-genai-data-security-risks-mitigations-2026.pdf
40. Scaling Self-Evolving Agents via Parametric Memory - arXiv, https://arxiv.org/pdf/2606.04536
41. Rethinking Expressivity and Efficiency in Test-Time Training - arXiv, https://arxiv.org/pdf/2608.21308
42. Continual Learning in Transition - arXiv, https://arxiv.org/html/2608.06216v2
43. A Behavioral Evaluation Framework for Deployment-Memory Claims, https://arxiv.org/pdf/2607.00368
44. MemCodex: Self-Programming Hierarchical - arXiv, https://arxiv.org/pdf/2609.39765
45. Learning to Forget: Sleep-Inspired Memory Consolidation for ... - arXiv, https://arxiv.org/html/2603.14517v1
46. Language Models Need Sleep - arXiv, https://arxiv.org/html/2605.26099v1
47. AI Agent Memory Architecture That Actually Works - Blake Crosley, https://blakecrosley.com/blog/ai-agent-memory-architecture
48. CraniMem: Cranial Inspired Gated and Bounded Memory for Agentic, https://arxiv.org/abs/2603.15642
49. Cognitive Memory in Large Language Models - Semantic Scholar, https://www.semanticscholar.org/paper/Cognitive-Memory-in-Large-Language-Models-Shan-Luo/d1958a7fc89303cad736884bd52c7d1dfd4469b5
50. Daily Papers - Hugging Face, https://huggingface.co/papers?q=memory%20systems
51. Structured Distillation for Personalized Agent Memory - arXiv, https://arxiv.org/pdf/2603.13017
52. Structured Distillation for Personalized Agent Memory: 11 - arXiv, https://arxiv.org/html/2603.13017v1
53. Qualixar — AI Reliability Engineering, https://qualixar.com/
54. SuperLocalMemory V3.3: The Living Brain -- Biologically-Inspired, https://huggingface.co/papers/2604.04514
55. Mem0 vs Letta: Best Letta Alternative for Production AI Agent Memory, https://mem0.ai/compare/mem0-vs-letta
56. Mem0 vs Zep vs Letta vs Cognee: Which to Use in 2026, https://particula.tech/blog/agent-memory-frameworks-tested-mem0-zep-letta-cognee-2026
57. Mem0 vs Zep vs Letta vs LangMem vs Cognee, benchmarked, https://datapace.ai/blog/ai-agent-memory-tools-2026