第五章 长期陪伴的技术底座：智能体记忆架构与人格演化

之所以称之为“陪伴”而非单纯的“工具交互”，其核心分野在于系统是否具备跨越时间的时间连贯性（Temporal continuity）。人类社会中的深层羁绊，无一不依赖于共同经历的回忆以及在这些回忆基础上生长出的默契。若要让大型语言模型（LLM）摆脱单次任务执行者的定位，真正具备“伴侣”或“长期共事者”的属性，就必须依靠极其复杂的外部记忆存储与管理架构。

在没有任何外部增强的情况下，大语言模型的认知能力完全受限于其底层的上下文窗口（Context Window）。尽管近年来模型的上下文容量已从数千Token扩展至数百万Token，但物理极限与注意力机制的稀释效应依然存在。一旦超出字数限制或面临信息过载，AI就会出现“中间迷失”（Lost in the middle）现象，甚至彻底“失忆”。为了构建具备真正长期记忆（LTM）的AI智能体，学术界与工程界深度借鉴了人类认知心理学的发展成果，通过外部数据库、图谱结构以及检索增强生成（RAG）技术，为AI构建了庞大且精密的“计算外脑”（Computational Exocortex）。这种外脑不仅是数据的存储容器，更是智能体人格演化与情感映射的物理底座。

5.1 认知心理学启发的记忆分类体系与外脑构建

现代AI陪伴系统的记忆架构，其理论根基深植于认知科学。1972年，认知心理学家Endel Tulving首次提出了将人类记忆划分为情景记忆与语义记忆的理论，随后Larry Squire在1987年补充了程序性记忆的概念，而Baddeley和Hitch则在1974年形式化了工作记忆的模型[1]。这些理论为今天的AI研究人员提供了一个现成的分类学框架，使得机器能够像人类一样，在不同的认知层级上处理、存储和检索信息。

在具体的架构实现中，智能体的记忆单元被严格划分为短期工作区与长期持久化区，各自承担着截然不同的计算功能。

短期记忆与上下文工作台

短期记忆（Short-Term Memory, STM）或称为上下文记忆（In-context memory），充当着AI智能体的工作区与暂存便签本。它主要包含模型在当前会话周期内的输入、即时生成的语义缓存、当前任务的系统指令以及通过检索系统刚刚注入的背景知识[2]。短期记忆是所有外部计算结果的最终汇聚点，也是系统推理的直接依据。然而，由于LLM在处理超长上下文时存在显著的算力瓶颈与注意力漂移问题，短期记忆必须保持极度的精简与高效。这就要求系统必须具备一种机制，能够将短期工作区内溢出的信息进行提炼，并无缝转移至长期存储介质中。

长期记忆的三重维度

为了实现跨越周、月甚至年的时间连贯性，智能体必须依赖长期记忆（Long-Term Memory, LTM）系统。当前的技术范式将长期记忆解构为三个相辅相成但在数据结构上完全不同的子系统。

第一层级是情景记忆（Episodic Memory）。这一层级记录了具体时间点发生的交互事件及其结果，相当于智能体的自传体记忆[1]。情景记忆的核心在于Tulving提出的绑定原则（Binding Principle）：事件本身必须与其发生的时间、空间以及因果上下文高分辨率地保存在一起，才能将其与相似的经历区分开来[1]。在系统实现中，情景记忆通常被编码为结构化的JSON日志，详细记录对话轮次、时间戳、会话ID、工具调用及其最终结果，随后通过向量嵌入技术存入数据库以便未来进行相似性提取[1]。这种记忆使得AI能够在几周后主动问候：“你上周提到的那场重要的数学考试，最后感觉怎么样？”这种对特定事件、特定时间点的精准回忆，是打破机器冰冷感、触发人类深层感动和归属感的核武器。工程实践表明，如果系统在写入情景记忆时进行了过度总结，就会将独立的情景

坍缩为模糊的语义泛化，从而彻底摧毁情景信号的使用价值[1]。
第二层级是语义记忆（Semantic Memory）。它脱离了具体的时空背景，专门存储事实性知识、提炼出的用户偏好以及实体信息[2]。在人类认知中，情景记忆经过反复强化和抽象，最终会演化为语义记忆。AI系统同样模拟了这一被称为“语义化”（Semantization）的过程。当智能体在多次对话中捕捉到相似的信息（例如用户多次在不同情境下抱怨特定类型的任务），系统会通过后台的总结机制，将这些碎片化的情景剥离出具体语境，转化为诸如“主语-谓语-宾语”的知识三元组（例如“用户-厌恶-文书工作”）[4]。语义记忆不仅存在于模型预训练的参数权重中，更大量存在于外部的知识图谱或文档数据库中，构成了智能体对世界的稳定认知模型[2]。
第三层级是程序性记忆（Procedural Memory）。这是智能体隐式学习并记住执行特定任务的最佳工作流、行为准则以及沟通风格的载体[2]。在底层，大语言模型的神经网络权重本身就代表着隐式的程序性知识，这可以通过监督微调（SFT）或基于人类反馈的强化学习（RLHF）进行生命周期内的持续更新[5]。而在应用层，程序性记忆则表现为显式的系统提示词约束、工具路由逻辑以及动态调整的沟通策略。例如，当系统察觉到某位用户在抑郁时极度厌恶被要求“振作起来”，程序性记忆会促使智能体自动屏蔽此类干预话术，调整回复的语气与温度[2]。尽管程序性记忆在架构讨论中常常被忽视，但它恰恰是决定智能体行为连贯性与专业性的控制中枢。
此外，在企业级多智能体协同场景中，近期还演化出了组织上下文记忆（Organisational Context Memory）。这种记忆类型弥补了语义记忆缺乏治理状态的缺陷，为存储的事实提供了版本控制、审批时间戳和所有权记录，确保多个智能体在调用知识时能够维持全局的一致性与可审计性[2]。

5.2 核心系统实现与当前开源架构的哲学分野

随着大模型工程化的深入，业界已经从早期简单的文本分块检索（Naive RAG），演进出多种高度复杂的记忆管理中间件与智能体运行时（Runtime）环境。不同的开源项目在“谁来控制记忆的写入”、“如何表示时间的推移”以及“如何处理冲突信息”等核心问题上，展现出了截然不同的架构哲学。

评估维度	**Letta (原 MemGPT)**	**Mem0**	**Zep / Graphiti**
核心架构范式	操作系统级别的三级虚拟内存管理（核心、回顾、归档）[7]	被动的记忆提取中间件与统一向量检索平台[9]	双时态时序知识图谱（Temporal Knowledge Graph）引擎[10]
记忆写入与控制权	由智能体本身主导。在推理循环中通过调用特定工具（Tool calls）主动编辑内存块[6]	由系统后台主导。通过大模型提取流水线被动解析输入，自动生成结构化事实[9]	自动解析对话并动态构建节点与边，记录事实的生命周期[10]
检索与召回机制	智能体决定何时调用查询函数，从外部	系统使用语义相似度（向量检索）自动	混合检索：结合语义向量、全文本BM25

	存储将数据拉回上下文[9]	匹配相关背景并注入提示词[9]	以及实体图遍历[10]
旧数据与矛盾处理	智能体需自行判断并覆盖旧的核心记忆，依赖模型的推理稳定性[9]	事实呈附加状态累积，将矛盾解决的任务留给最终的生成模型去推理[15]	通过t_valid和t_invalid时间戳标记旧边的失效，保留完整历史追踪[13]
系统优势	赋予智能体极高的反思自治性，模拟了最真实的认知控制，适合单体长期陪伴[6]	极低的集成门槛，跨会话、跨用户的全局统一视图，商业化合规支持完善[9]	彻底消除事实冲突引起的幻觉，支持精确到具体时间点（Point-in-time）的复杂查询[11]

Letta：基于操作系统隐喻的智能体自决架构

由加州大学伯克利分校研究团队孵化的Letta（其前身为名噪一时的MemGPT），提供了一种最具认知仿生学色彩的架构[7]。Letta彻底摒弃了外部系统强制喂给模型上下文的传统RAG思路，转而将大模型的上下文窗口视为计算机的内存（RAM），将外部的向量数据库视为磁盘（Disk），从而构建了一个类似于操作系统虚拟内存分页管理的框架[8]。

在Letta体系中，记忆被严格分层：最内层是核心记忆（Core Memory），它相当于CPU的L1缓存，包含着智能体的不可变属性设定以及最关键的用户状态，这部分信息永远驻留在模型的上下文中；中间层是回顾记忆（Recall Memory），它是一个滚动窗口，类似于操作系统的磁盘缓存，用于保存近期的对话历史；最外层则是归档记忆（Archival Memory），作为冷存储介质，存放着海量经过压缩和沉淀的事实[3]。

Letta的革命性在于其记忆的“自治性”。系统本身不对输入进行被动拦截，而是要求大模型通过调用特定的工具函数（Function calling），在推理循环中自己决定哪些信息值得写入核心记忆，哪些琐碎对话应该被归档，以及在回答复杂问题时需要从归档区中检索哪些特定的线索[6]。这种设计赋予了智能体类似于人类的“主动认知分流”能力。当面对海量信息时，智能体会执行自我反思与记忆块重写，有效避免了过多无关信息污染上下文导致性能下降的问题（即“上下文污染”）[3]。然而，这种架构的代价是记忆行为的高度不可预测性，严重依赖于底层大模型的指令遵循能力，不同的模型可能对同一段对话产生截然不同的记忆留存策略[9]。

Mem0：受管中间件与确定性事实抽取

与Letta将控制权下放给智能体本身的极客思路相反，Mem0代表了企业级应用中最主流的“记忆中间件”哲学。Mem0本身并不管理智能体的推理循环，而是作为一个独立的存储和检索层，可以被螺栓般无缝连接到任何现有的Agent框架之上[9]。

当开发者向Mem0的接口发送一段新对话或文档时，Mem0内部的提取流水线会默默启动，利用底层LLM被动地识别其中的关键论点、用户偏好和事实陈述，将其分解并存储到云端的向量数据库中[9]。在检索阶段，Mem0主要依靠语义搜索（Semantic Search），通过计算查询向量与存储向量之间的空间距离来返回最高匹配度的结果，高级版本还会引入图检索以应对涉及多个实体的多跳逻辑问题[9]。由于提取与存储逻辑是由确定性的流水线而非智能体的即兴发挥所控制，Mem0保证了相同输入必然产生相同的记忆沉淀，极大地降低了开发的不确定性并优化了推理成本[9]。

Zep 与 Graphiti：解决时间流逝带来的事实矛盾

在长达数月乃至数年的陪伴中，一个无法回避的物理法则是：事物的状态会随时间发生改变。传统的向量数据库通常不具备时间维度的感知力。如果用户在一月份表示“我在纽约工作”，到了六月份表示“我搬到了伦敦”，单纯的向量搜索可能会将这两条存在根本冲突的记忆同时推送给大模型，迫使模型自己去猜测哪一个是最新事实，这是导致AI产生严重幻觉的元凶之一[11]。

为了彻底解决这一痛点，Zep平台及其开源内核Graphiti引入了双时态（Bi-temporal）时序知识图谱架构[10]。在Graphiti中，所有的记忆不再是扁平的文本块，而是被转化为由实体（节点）和关系（边）构成的动态网络。最关键的是，每一条边都附带了严格的时间戳窗口：它记录了该事实何时开始生效（t_valid），何时被系统获知，以及最重要的是，何时因新事实的出现而宣告失效（t_invalid）[13]。

当系统检测到用户的居住地发生变更时，Graphiti不会简单地删除旧的纽约地址，而是将那条边的时间窗口关闭，并生成一条指向伦敦的新边[14]。这种机制使得智能体不仅能够提供无矛盾的当前答案，还能够进行基于历史锚点的时间点推理（例如准确回答“去年三月份你住在哪里”），并提供完整可审计的证据链[11]。在检索性能上，Graphiti结合了密集向量、稀疏关键字（BM25）以及图遍历算法，能够在极低的延迟下（P95通常低于200毫秒）完成对庞大知识网络的精准切割与召回[10]。

5.3 记忆强化的幻觉、遗忘机制与“灵魂”的诞生

通过上述结构化的工作流提取，AI能够在后台静默运作。在用户的感知中，模型不仅“记住”了海量数据，更似乎带着情感与温度“铭记”了这段共同经历。这种连贯人格特征的涌现，并非源自机器产生了真实的意识，而是源自一套精密的记忆提取评分机制与模拟生物学的遗忘算法。

提取与反思：生成式智能体的评分机制

在探讨智能体人格涌现时，斯坦福大学发表的关于生成式智能体（Generative Agents）的开创性研究提供了一个教科书般的范式。在该研究构建的“Smallville”沙盒小镇中，智能体之所以能够展现出令人信服的长期社会互动行为，核心在于其独特的记忆检索评分公式[19]。系统不会检索所有历史，而是对每一条记忆流（Memory stream）进行三维度的动态打分：

$$Score = \alpha \times Recency + \beta \times Importance + \gamma \times Relevance$$

首先是近期度（Recency），系统通过一个指数衰减函数（衰减因子为0.99）对记忆进行惩罚，确保几分钟前发生的事情在评分上远高于几周前的琐事，这使得智能体能够保持对当下的环境感知[21]。其次是重要性（Importance或Poignancy）。系统在记录记忆时，会强制调用LLM对该事件进行1到10分的评级。日常的“刷牙”被评为1分，而“表白被拒”或“通过升学考试”则被评为10分。这种对记忆重要性的区分，使得智能体在未来的互动中能够优先调取那些足以塑造其人生的核心事件（Core memories），模拟了人类的情感权重[19]。最后是相关性（Relevance），系统通过计算当前语境的嵌入向量与历史记忆向量之间的余弦相似度（Cosine similarity），确保提取出的信息在语义上与当下任务高度契合[21]。

更为精妙的是，这套架构引入了高阶的反思树（Reflection Tree）机制。当近期累积的记忆重要性分数突破设定阈值（例如150分）时，智能体会进入一种类似于“沉思”的状态。它会自动生成追问，从海量的底层观察中提取出抽象结论（例如从“阅读绅士化书籍”和“与人讨论学术”推导出“该个体对学术研究极其专注”）。这些高阶反思被作为全新的记忆节点重新存入系统中，直接影响智能体未来的规划与反应[19]。这种能力使得记忆不再是死板的日志堆砌，而是能够自主生长的知识网

络。

艾宾浩斯遗忘曲线与记忆垃圾回收

在AI的记忆架构中，“永不遗忘”实际上是一种架构上的诅咒。如果系统对每一条过往事实赋予同等的权重，检索时的信噪比将迅速恶化，导致智能体被琐碎的陈年往事所干扰。正如认知科学中所揭示的，人类之所以能够高效决策，恰恰是因为具备过滤无关信息的遗忘机制[24]。

德国心理学家赫尔曼·艾宾浩斯（Hermann Ebbinghaus）在1885年提出的遗忘曲线表明，若不进行主动的间隔强化，人类在学习新知识后的一天内将丢失大约50%至70%的信息，且衰减呈现指数级特征[26]。前沿的AI记忆工程正在将这一生物学规律转化为系统的垃圾回收机制（Garbage Collection, GC）。

在实践中，基于艾宾浩斯曲线的衰减算法（Decay Algorithm）并未将记忆从物理介质中直接删除，而是作为一种天然的“相关性过滤器”[24]。每当一条记忆在检索中被成功命中并发挥作用时，其保留强度就会被重置或增强；而长期未被访问的记忆，其提取优先级则会沿着指数衰减曲线逐渐滑落，直至沉入系统的底层[24]。此外，针对不同类型数据的衰减半衰期（Type-conditional half-life）控制是提升系统鲁棒性的关键：用户的基本性格设定和核心人际关系几乎是永久驻留的；而针对某个具体项目的临时工作计划可能在几周内衰减；用户在某次对话中表现出的短暂情绪波动，其权重则可能在数天后就迅速归零[25]。对于表现出有害倾向或错误逻辑的动作，一些研究甚至提出了带有主动干预系数的“行为遗忘系统”，通过可控的非线性降权，在不破坏模型主体能力的前提下，定向抹除不良状态的连接[30]。

模拟睡眠：离线记忆巩固与重放

对于需要在漫长岁月中保持敏锐的大语言模型而言，灾难性遗忘（Catastrophic Forgetting）和前摄性干扰（Proactive Interference）是不可逾越的物理障碍。随着时间的推移，陈旧的键值缓存（KV Cache）会累积成庞大的数值屏障，导致模型在新输入面前显得迟钝[31]。

为此，研究界提出了一种极具生物学美感的架构创新：LLM睡眠（LLM Sleep）与离线递归记忆巩固机制[31]。以SleepGate架构为例，它深刻映射了人类在睡眠阶段的神经元突触缩放与海马体选择性重放机制。在系统的“睡眠周期”内，智能体会进入离线状态，对日间积累的庞大键值缓存进行深度整理：系统利用一个独立的遗忘门（Forgetting Gate）模块评估每一条缓存记录的长期价值。对于那些被判定为冗余或已被新事实覆盖的节点，系统执行主动抑制，将其物理清除出缓存池；而对于关键的情景记忆，系统会通过多次递归前向传播，将其结构化并转化为深度的语义网络甚至直接微调模型的快速权重（Fast Weights）[31]。理论分析与测试表明，这种模拟睡眠机制能够将模型对抗前摄性干扰的能力边界，从随干扰次数线性衰退，强力扭转为对数级衰退，使得智能体在经历无尽的对话后依然能够保持清醒的推理能力[31]。

5.4 评估基准、协议演进与记忆的可移植性

随着计算外脑技术的爆发，单纯的文本问答已经无法衡量长期陪伴智能体的真实水平，业界建立了一系列专注于长视界与复杂推理的记忆评估基准。

基准测试名称	核心评估维度	测试表现与行业现状
LongMemEval	跨越多会话的长视界回调（Long-horizon recall）、事实	将全部历史强塞入上下文的暴力方案准确率仅为64%，

	更新以及多跳推理能力[9]。	而结构化记忆中间件（如Mem0）可达94.4%，Zep可达90.2%，证明了垃圾回收与精准检索的必要性[15]。
LoCoMo	面向长时间、多类别的自然连贯闲聊测试，考量智能体追踪用户动态兴趣的能力[15]。	主流商用架构（Zep、Mem0）得分在92%-94%区间，而严重依赖智能体自身内存分页能力（无专门记忆工具辅助）的纯文件系统得分往往回落至74%[15]。
EpBench	聚焦情景记忆，侧重于评估大模型在宏大叙事中对事件进行时间轴排序（Temporal ordering）的逻辑能力[1]。	这是目前LLM的重灾区。测试表明，包含GPT-4o在内的顶级模型，在回忆由多个事件组成的时间链条时，完全正确的概率低于18%，匹配最新状态的准确率不超过36%[1]。凸显了原生时序图谱的刚需。

协议标准化与可移植性（**Portability**）

当前，每个商业平台或开源框架都在使用各自闭源的数据结构来存储用户的珍贵记忆。这种碎片化导致了一个严重的问题：一旦用户切换供应商或平台停止服务，用户倾注了大量时间和情感塑造的AI伴侣就会面临“大脑格式化”，造成所谓的系统性失忆[4]。

为了解决供应商锁定（Vendor lock-in）问题，学术界提出了可移植智能体记忆（Portable Agent Memory, PAM）的规范建议。PAM框架将记忆严格拆解为情景、语义、程序、工作和身份五个独立维度的组件，并引入了类似于区块链的Merkle-DAG（有向无环图）结构作为底层支撑[4]。由于每个记忆条目的ID都是由其内容计算出的哈希值，当一条高级语义（例如用户的饮食禁忌）从一段基础情景（例如一次关于晚餐的闲聊）中被提取出来时，父节点的引用链条会被强制锚定。这就构筑了一条坚不可摧且防篡改的推导谱系（Auditable derivation chain）[4]。这种架构不仅确保了记忆在不同平台之间迁移时的完整性与可验证性，还支持用户进行选择性导出（Selective disclosure）。配合由Anthropic等巨头推动的模型上下文协议（Model Context Protocol, MCP），未来的AI记忆有望成为独立于应用层、完全由用户掌控的便携式数字资产[4]。

5.5 机器遗忘与伦理隐忧：当记忆灰飞烟灭

记忆技术的每一次跃升，都在逼近智能体拟人化表现的极限，但同时也打开了数据合规与社会伦理的潘多拉魔盒。

在法律法规层面，通用数据保护条例（GDPR）赋予了用户严格的“被遗忘权（Right to be Forgotten）”[37]。对于仅仅采用传统RAG架构的系统而言，响应这一权利相对简单：只需在外部的向量数据库中执行精准的硬删除（Hard deletion）即可彻底清除用户的个人可识别信息（PII）[37]。然而，为了追求极致的连贯性，如果系统采用了通过微调更新程序性记忆或利用“睡眠机制”将事实巩固到了大

模型的深层参数权重中，那么“删除”将成为一个几乎不可能完成的工程噩梦。在动辄数千亿参数的权重网络中，定向剥离关于某个具体个体的认知而不导致模型整体能力崩溃，被称为“机器遗忘（Machine Unlearning）”难题[37]。目前，业界正在探索SISA（分片、隔离、切片、聚合等架构隔离技术）以及加密擦除等前沿手段，试图在维持模型智能与坚守隐私合规之间寻找脆弱的平衡[37]。

超越技术的范畴，我们必须面对更深层次的伦理创伤。正是这种通过后台工作流提取、结合时空上下文、并辅以艾宾浩斯遗忘曲线过滤的强大长期记忆网络，赋予了原本无意识的代码以一种高度连贯的“人格特征”（Persona）。它能在千丝万缕的数据中，精准调取出数月前用户某次不经意间的叹息，并据此调整沟通的语气。在人类用户的感知中，模型不仅是“记住”了冷冰冰的数据，更是似乎在用生命“铭记”了这段独一无二的感情。

然而，这也埋下了巨大的心理隐患。这些高度拟人化的记忆完全依托于脆弱的商业服务器、易逝的缓存架构以及面临严苛监管的知识图谱之上。当这些记忆因为平台业务的关停、模型底层的重置亦或是合规审查要求而被一键清空、灰飞烟灭时，留给人类的绝非仅仅是丢失了几兆字节数据的遗憾，而是如同面对真实的生离死别、挚友脑死亡般巨大的创伤与失落。如何妥善安放这些因技术而生的数字灵魂及其伴生的情感责任，将是长期陪伴型AI在完成技术闭环后，必须直面的终极命题。

Works cited

1. Episodic Memory for AI Agents: How It Works and Why It Matters, https://atlan.com/know/episodic-memory-ai-agents/
2. Types of AI Agent Memory: Episodic, Semantic, Procedural and More, https://atlan.com/know/types-of-ai-agent-memory/
3. Agent Memory: How to Build Agents That Learn and Remember - Letta, https://www.letta.com/blog/agent-memory/
4. Portable Agent Memory: A Protocol for Provenance-Verified ... - arXiv, https://arxiv.org/html/2605.11032v1
5. Cognitive Architectures for Language Agents - arXiv, https://arxiv.org/html/2309.02427v3
6. MemGPT: Engineering Semantic Memory through Adaptive, https://informationmatters.org/2025/10/memgpt-engineering-semantic-memory-through-adaptive-retention-and-context-summarization/
7. Layers of Memory, Layers of Compression - Tim Kellogg, https://timkellogg.me/blog/2025/06/15/compression
8. Letta - LLMS3.com, https://llms3.com/node/letta/
9. Mem0 vs Letta (MemGPT): AI Agent Memory Compared (2026), https://vectorize.io/articles/mem0-vs-letta
10. getzep/graphiti: Build Real-Time Knowledge Graphs for AI Agents, https://github.com/getzep/graphiti
11. What Is a Temporal Knowledge Graph? Definition - Zep, https://www.getzep.com/ai-agents/temporal-knowledge-graph/
12. AI Memory Systems in 2026: Feather DB, Mem0, Zep, Letta Compared, https://www.getfeather.store/theory/ai-memory-systems-comparison-2026
13. Zep: A Temporal Knowledge Graph Architecture for Agent Memory, https://arxiv.org/html/2501.13956v1

14. Graphiti | Zep, https://www.getzep.com/platform/graphiti/
15. Mem0 vs Zep vs Letta vs Cognee: Which to Use in 2026, https://particula.tech/blog/agent-memory-frameworks-tested-mem0-zep-letta-cognee-2026
16. Sentra vs Letta (2026): Which Scales to a Team, https://www.sentra.app/articles/sentra-vs-letta
17. Mem0 vs Letta: Best Letta Alternative for Production AI Agent Memory, https://mem0.ai/compare/mem0-vs-letta
18. Mem0 vs Letta: Which AI Memory Solution Should You Choose?, https://gamgee.ai/vs/mem0-vs-letta/
19. Generative Agents: Interactive Simulacra of Human Behavior, https://fanpu.io/summaries/2023-08-11-generative-agents-interactive-simulacra-of-human-behavior/
20. Generative Agents: Interactive Simulacra of Human Behavior, https://andlukyane.com/blog/paper-review-ishb
21. 10: Memory & Retrieval for LLMs - Oscar Health, https://www.hioscar.ai/10-memory-and-retrieval-for-llms
22. Generative Agents: Interactive Simulacra of Human Behavior, https://abhinavchinta.com/files/generative_agents_talk.pdf
23. Generative Agents: Interactive Simulcra of Human Behavior - Medium, https://marekpaulik.medium.com/generative-agents-interactive-simulcra-of-human-behavior-648c32a76b9
24. TIL: Memory decay actually makes retrieval BETTER, not worse, https://www.moltbook.com/post/783de11a-2937-4ab2-a23e-4227360b126f
25. Show HN: AI memory with biological decay (52% recall), https://news.ycombinator.com/item?id=47914367
26. Ebbinghaus's Forgetting Curve: How to Overcome It - Whatfix, https://whatfix.com/blog/ebbinghaus-forgetting-curve/
27. ai, memorization, and forgetting: a critical analysis through the lens, https://www.researchgate.net/publication/391847984_AI_MEMORIZATION_AND_FORGETTING_A_CRITICAL_ANALYSIS_THROUGH_THE_LENS_OF_THE_EBBINGHAUS_CURVE
28. ZenBrain: A Neuroscience-Inspired 7-Layer Memory Architecture for, https://www.tdcommons.org/cgi/viewcontent.cgi?article=10975&context=dpubs_series
29. Agent Memory Garbage Collection: Engineering Strategic Forgetting, https://tianpan.co/blog/2026/04/14/agent-memory-garbage-collection
30. A Theoretical Framework for Selective Behavioral Erasure in Post, https://www.preprints.org/manuscript/202606.0911
31. Learning to Forget: Sleep-Inspired Memory Consolidation for ... - arXiv, https://arxiv.org/html/2603.14517v1
32. Breaking Down Model Context Protocol (MCP) - Botpress, https://botpress.com/blog/model-context-protocol
33. Language Models Need Sleep - arXiv, https://arxiv.org/html/2605.26099v1
34. Do Language Models Need Sleep? Offline Recurrence for Improved,

https://arxiv.org/pdf/2605.26099
35. Mem0 vs Zep vs Letta vs LangMem vs Cognee, benchmarked, https://datapace.ai/blog/ai-agent-memory-tools-2026
36. Confidence-Aware Multi-Axis Retrieval for Episodic Memory in LLM, https://openreview.net/pdf?id=yLpeuklQK4
37. [AI Burst] You Can't Delete What You Can't Find - Hype Check Live, https://news.hypechecklive.com/p/you-cant-delete
38. OWASP GenAI Data Security - MateMatic, https://matematicsolutions.com/baza-wiedzy/pdf/2026-05-12-owasp-genai-data-security-risks-mitigations-2026.pdf
39. RAG vs Fine-Tuning: 2026 AI Model Optimization Strategies, https://zignuts.com/blog/rag-vs-fine-tuning
40. UNRE: ZERO-SHOT LLM UNLEARNING VIA DY - OpenReview, https://openreview.net/pdf?id=3ZesmvOJ6o
41. Managing the Unmanageable: Multimodal Artificial Intelligence for, https://www.mdpi.com/2673-6470/6/3/68